Introdução à Programação Concorrente

Paulo Sérgio Almeida

Grupo de Sistemas Distribuídos Departamento de Informática Universidade do Minho



Sistemas concorrentes

- Processos correm concorrentemente num sistema:
 - Com pseudo-concorrência, partilhando tempo de CPU;
 - Com verdadeira concorrência, num multi-processador ou num sistema distribuído;
- Com concorrência os processos:
 - executam acções independentemente;
 - em modelos simplificados, acções são consideradas atómicas
 - correm com velocidades relativas imprevisíveis;
 - com partilha de tempo, acções são intercaladas imprevisivelmente;
 - com paralelismo verdadeiro, acções decorrem simultaneamente;
- Exemplos de acções:
 - leitura de posição de memória
 - escrita em posição de memória
 - envio de mensagem
 - recepção de mensagem



Comunicação e sincronização

- Vários processos podem querer cooperar num objectivo comum;
- Duas necessidades se verificam: comunicação e sincronização;
- Comunicação:
 - passagem de informação entre processos;
 - processo produz itens que v\u00e3o ser usados por outro;
 - processo servidor recebe pedidos de clientes e devolve resultados;
- Sincronização:
 - processos podem ter que esperar antes de poder prosseguir;
 - normalmente associada à comunicação;
 - esperar até item estar disponível para o consumir;
 - esperar até resposta ser devolvida;
 - esperar que todos tenham terminado respectivas tarefas;
 - esperar que todos os componentes estejam iniciados;
 - esperas activas indesejáveis



Processos e threads

- Um processo começa com uma thread de execução; outras podem ser criadas em seguida;
- As threads dos vários processos correm concorrentemente;
- Cada processo possui o seu espaço de endereçamento privado;
- Todas as threads criadas dentro do mesmo processo:
 - partilham memória (variáveis globais e heap) e recursos globais;
 - mantêm o seu stack com variáveis locais privadas;
- Threads podem ser vistas como processos leves que permitem cooperação eficiente via memória;
- Podem também ser pedidos ao SO segmentos de memória partilhada entre processos;
- Vamos usar frequentemente a palavra processo no sentido lato, que engloba possível partilha de memória;



Partilha de memória versus mensagens

- Duas grandes famílias de paradigmas existem:
 - Com memória partilhada + primitivas de sincronização;
 - Com troca de mensagens;



Mensagens

- Diferentes primitivas:
 - Primitivas básicas tipo send/receive;
 - Cliente-servidor:
 - Broadcast/multicast:
 - Abstracções de mais alto nível; e.g., comunicação em grupo.
- Comunicação síncrona ou assincrona;
- Comunicação orientada à conexão;
- Formalismos; e.g. CSP Communicating Sequencial Processes

(Deixaremos concorrência baseada em mensagens para mais tarde)



Concorrência em memória partilhada

- As acções dos processos intercaladas de modo imprevisível;
- Acesso concorrente a dados partilhados gera inconsistência;
- É necessário primitivas de controlo de concorrência;
- Primitivas clássicas:
 - semáforos
 - monitores
- Monitores particularmente importantes onde são baseadas primitivas de muitas linguagens modernas;
- Monitores levam a tipos abstractos de dados concorrentes



Intercalamento, partilha e visibilidade

- Intercalamento e "memória partilhada" é um modelo simplificado, mas suficiente para ilustrar muitos problemas;
- Na realidade, temos multicores / multiprocessadores;
- Temos hierarquias de memória: registos, caches, RAM;
- Temos optimizações dos compiladores;
- Váriavel partilhada pode estar temporariamente em registo;
- "Memória partilhada" pode não reflectir escritas;
- É necessário primitivas de controlo de concorrência:
 - não só para sincronização;
 - mas para dar visibilidade das escritas às outras threads;
- Modelo de coerência de memória especifica visibilidade;
- Estudaremos brevemente um modelo de memória mais realista;



Race conditions – corridas

Race condition - corridas

Quando processos manipulam concorrentemente estrutura de dados partilhada, e o resultado depende da ordem dos acessos

Exemplo:

- Vários processos acedem a um contador partilhado;
- Cada processo tenta incrementar o contador com:

```
contador = contador + 1
```

 Esta instrução é traduzida para instruções máquina que usam registos, e.g.

```
MOV contador, R0
ADD R0, 1
MOV R0, contador
```

 Dado que a execução dos processos pode ser intercalada de diferentes modos, o que pode acontecer ao contador?



Secções críticas

- Um segmento de código que acede a recursos partilhados é uma secção crítica;
- As secções críticas têm que ser submetidas a controlo de concorrência, caso contrário temos race conditions;
- As secções críticas são por recurso: podemos ter concorrência envolvendo recursos diferentes;
- Uma secção crítica deve ser rodeada por código de entrada (que pede permissão para entrar) e saída;

```
codigo de entrada
seccao critica
codigo de saida
...
```



Problema das secções críticas

Cada processo quer aceder um número arbitrário de vezes em momentos arbitrários a secções críticas sobre um dado recurso.

Uma solução para o problema das secções críticas deve garantir:

exclusão mútua se um processo está a executar uma secção crítica, mais nenhum o pode estar;

ausência de deadlock se vários processos estão a tentar entrar numa secção crítica, um deles deve conseguir;

ausência de starvation se um processo tenta entrar numa secção crítica, inevitavelmente vai entrar.



Problema das secções críticas

Outra formulação para o problema:

- exclusão mútua se um processo está a executar uma secção crítica, mais nenhum o pode estar;
 - progresso se nenhum processo estiver numa secção crítica e alguns processos quiserem entrar, apenas os processos que executam o código de sincronização podem participar na decisão de quem entra; esta decisão não pode ser adiada indefinidamente;
- espera limitada existe um limite para o número de vezes que outros processos podem entrar passando à frente de um processo que já pediu entrada.



Soluções por software para secções críticas

- Será possível arranjar solução para o problema sem ajuda de hardware?
- Suponhamos modelo simplificado com intercalamento de acções atómicas (leituras e escritas) e visibilidade imediata;
- Suponhamos que podemos fazer esperas activas:

```
while(...)
...
// seccao critica
```

- Poderemos obter o código de entrada e saída da secção crítica manipulando variáveis partilhadas de um modo cuidadoso?
- Pensemos no caso particular de 2 processos, P₀ e P₁;



Solução de Peterson para as secções críticas

- Exemplo clássico de solução por software;
- Restrito ao caso de 2 processos, P₀ e P₁;
- Na solução, dois itens são partilhados:

```
int vez;
boolean entrar[2];
```

Processo i executa:

```
entrar[i] = true;
vez = 1-i;
while (entrar[1-i] && vez == 1-i)
   ;
//
// seccao critica
//
entrar[i] = false;
```



Problemas com a solução de Peterson

- Exemplo clássico de solução por software;
- Restrita a 2 processos;
- Envolve espera activa;
- Assume implicitamente exclusão mútua de mais baixo nível:
 - atomicidade de acções de leitura/escrita na memória;
 - e.g., dois processos tentarem escrever em vez ao mesmo tempo;



Algoritmo bakery de Lamport para exclusão mútua

- Para N processos;
- Nenhuma variável é escrita por dois processos;
- Não assume atomicidade de leituras/escritas: quando leitura e escrita se sobrepôem, assume resultado arbitrário da leitura;

```
boolean choosing[N];
int number[N];
```

Processo i executa:



Soluções por hardware

Um padrão geral de solução pode ser obtido com locks:

```
adquirir lock
seccao critica
libertar lock
```

- O problema é passado para a implementação dos locks . . .
- Com ajuda de hardware temos diferentes possibilidades:
 - inibir interrrupções (em uniprocessadores);
 - instruções atómicas: test-and-set, swap, ...



Test-and-set

- Instrução que atomicamente:
 - o coloca o valor de uma flag a verdadeiro
 - devolve o valor que a flag tinha previamente
- Faz atomicamente o equivalente a:

```
boolean TestAndSet(boolean *pt) {
  boolean tmp = *pt;
  *pt = true;
  return tmp;
}
```



Exclusão mútua com test-and-set

- Usando test-and-set é fácil implementar exclusão mútua;
- Flag lock começa a false;
- Cada processo faz:

```
while (TestAndSet(&lock))
;
//
// seccao critica
//
lock = false;
```

Solução satisfaz todos os requisitos?



Swap

- Instrução que atomicamente troca o valor de duas posições de memória;
- Faz atomicamente o equivalente a:

```
void Swap(boolean *a, boolean *b) {
  boolean tmp = *a;
  *a = *b;
  *b = tmp;
}
```



Exclusão mútua com Swap

- Usando Swap é fácil implementar exclusão mútua;
- Flag lock começa a false;
- Cada processo faz:

```
key = true;
while (key == true)
   Swap(&key, &lock);
//
// seccao critica
//
lock = false;
```

Solução satisfaz todos os requisitos?



Exclusão mútua com espera limitada via test-and-set

- Solução para N processos;
- A solução usa como itens partilhados, iniciados a false:

```
boolean espera[N];
boolean lock;
```

O processo i executa:

```
espera[i] = true;
while (TestAndSet(&lock) && espera[i])
;
espera[i] = false;
//
// seccao critica
//
j = (i + 1) % N;
while (j != i && !espera[j])
    j = (j + 1) % N;
if (j == i)
    lock = false;
else
    espera[j] = false;
```



Esperas activas e o sistema operativo

- As soluções anteriores ainda envolvem esperas activas;
- Estas podem demorar tempo considerável, enquanto outros processos executam as suas secções críticas – inaceitável;
- Solução: o sistema operativo disponibilizar as primitivas (e.g. adquirir e libertar lock) para rodear as secções críticas;

```
acquire(&lock);
//
// seccao critica
//
release(&lock);
```

- Código do utilizador invoca primitivas de controlo de concorrência disponibilizadas, não contendo esperas activas;
- O problema foi passado para a implementação das primitivas ...



Implementação de primitivas pelo SO

- Na implementação das primitivas de concorrência, depois de uma curta espera activa, o kernel pode fazer um processo P passar ao estado bloqueado;
- O processo P, no estado bloqueado, não é escalonado, não consumindo tempo de processador;
- Mais tarde um processo Q invoca o libertar lock;
- O código desta primitiva trata de mudar o estado do processo P para pronto;
- O processo P pode então entrar na secção crítica da próxima vez que for escalonado.



Exclusão mútua versus ordem de execução

Na resolução de problemas de controlo de concorrência é útil distinguir duas situações:

- exclusão mútua: quando vários processos concorrem no acesso a recursos partilhados:
 - caso particular muito comum;
 - processo apenas é impedido de prosseguir temporariamente;
 - com apenas um processo, este corre sempre sem problemas;
 - vulgarmente papeis simétricos;
- ordem de execução: quando existem padrões de cooperação e dependência entre acções de processos:
 - um processo n\u00e3o pode prosseguir at\u00e9 ac\u00e7\u00e3o de outro;
 - processos bloqueiam-se voluntariamente;
 - processos s\u00e3o libertados por outros;
 - exige normalmente mais do que um processo;
 - vulgarmente papeis diferentes (e.g., produtor e consumidor);



Exemplo de exclusão mútua: jantar dos filósofos

- Problema clássico de programação concorrente
- Cinco filósofos alternam entre pensar e comer esparguete, sentados à volta de uma mesa redonda:
 - existem 5 pratos na mesa;
 - existem 5 garfos na mesa, um entre cada dois filósofos;
 - um filósofo necessita de dois garfos para poder comer;
 - um filósofo só pode pegar ou pousar um garfo de cada vez.
- Este é um problema de exclusão exclusão mútua envolvendo vários recursos, os garfos.
- Uma solução tem que também garantir:
 - segurança: cada filósofo só pode comer tendo dois garfos;
 - ausência de deadlock;
 - ausência de starvation;
 - eficiência na ausência de contenção.



Exemplo de ordem de execução: produtor-consumidor

- Outro problema clássico.
- Existem dois tipos de processos:
 - produtor: produz itens de dados;
 - consumidor: consome itens produzidos.
- Itens são produzidos e consumidos para um buffer partilhado, de tamanho limitado (bounded buffer).
- Uma solução tem que garantir que:
 - se o buffer está vazio, um consumidor não pode prosseguir, tendo que ficar bloqueado;
 - se o buffer está cheio, um produtor não pode prosseguir, tendo que ficar bloqueado.
- Estes problemas também podem envolver exclusão mútua (neste caso na manipulação do buffer).



Correcção de programas concorrentes

Existem dois tipos de propriedades:

- Segurança: determinada propriedade (invariante de estado) é sempre verificada:
 - exemplo: não estão dois processos na secção crítica;
 - exemplo: um filósofo só pode estar a comer com dois garfos;
 - a correcção diz respeito a certos estados nunca serem atingíveis.
- Animação: determinada propriedade será inevitavelmente (mais tarde ou mais cedo) verificada:
 - se processo quer entrar na secção crítica, acabará por entrar;
 - se filósofo quer comer, acabará por comer;
 - animação diz respeito a certos estados serem atingidos.



Algumas propriedades de animação

Casos particulares importantes de propriedades de animação:

- Ausência de deadlock:
 - nunca é atingido um estado do qual não haja saída (não possa ser feito progresso para um estado desejável);
- Ausência de livelock:
 - nunca é atingido um de vários possíveis estados dos quais não haja saída (para um estado desejável).
- Ausência de starvation:
 - quando um dado processo tenta continuamente efectuar uma dada acção, acaba por o conseguir;
 - exemplo: um processo só pode ser ultrapassado numa espera um número limitado de vezes.

